SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEK

FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni diplomski studij Računarstva

SINTETSKI ANGIOGRAMI IZ PROCEDURALNO GENERIRANIH VASKULARNIH MREŽA

Obrada slike i računalni vid

Lara Lacić

Osijek, 2026.

SADRŽAJ

1. UVOD 3

2. PREGLED PODRUČJA I PROBLEMATIKE 4

2.1. Angiografija i vaskularne mreže 4

2.2. Proceduralno generiranje vaskularnih mreža 4

2.3. Sinteza angiogramskih slika 5

2.4. State of the art – relevantni radovi i alati 6

3. OPIS ZADATKA S DOBIVENIM REZULTATIMA 8

3.1. Cilj zadatka 8

3.2. Metodologija 8

3.3. Dobiveni rezultati 9

3.4. Analiza i interpretacija rezultata 14

4. ZAKLJUČAK 16

LITERATURA 17

1. UVOD

U današnje vrijeme kardiovaskularne bolesti predstavljaju primarni uzrok smrtnosti na globalnoj razini. Među njima se posebno ističe koronarna arterijska bolest, koja nastaje zbog suženja ili potpune blokade arterija koje opskrbljuju srčani mišić krvlju. U kliničkoj praksi, angiografija se i dalje smatra "zlatnim standardom" za preciznu dijagnostiku ovakvih stanja, koristeći kontrastna sredstva za vizualizaciju krvnih žila. Međutim, proces anotacije i analize angiografskih snimaka izuzetno je kompleksan, financijski zahtjevan i dugotrajan, s obzirom na to da izravno ovisi o stručnosti kardiologa. [1]

Iako je implementacija dubokih neuronskih mreža pokrenula pravu revoluciju u obradi medicinskih slika, učinkovitost i robusnost ovih modela uvjetovane su postojanjem opsežnih i raznolikih skupova podataka za treniranje. Sakupljanje dovoljne količine stvarnih kliničkih snimaka u praksi nailazi na stroge regulatorne i logističke prepreke koje je teško zaobići. Kao rješenje ovog problema nametnula se paradigma generiranja sintetskih podataka. Kroz primjenu proceduralnih algoritama modeliraju se virtualne krvožilne mreže, što omogućuje simulaciju realističnih angiograma koji već u startu sadrže potpuno točne i automatski generirane oznake. [2]

2. PREGLED PODRUČJA I PROBLEMATIKE

2.1. Angiografija i vaskularne mreže

U kliničkoj praksi, angiografija predstavlja invazivnu dijagnostičku metodu koja se temelji na ubrizgavanju kontrastnog sredstva u arterijski sustav, čime se omogućuje jasna vizualizacija krvotoka pod rendgenskim zračenjem. Anatomiju srca u ovom kontekstu primarno definiraju dvije glavne koronarne arterije, lijeva (LCA) i desna (RCA), koje se progresivno granaju u složenu mrežu manjih krvnih žila. Pored samih koronarnih arterija, unutar srčanog prostora smještene su i pripadajuće vene, kao i manji krvožilni ogranci koji su okruženi epikardijalnim masnim tkivom [3].

Koronarna vaskularna mreža odlikuje se kompleksnom trodimenzionalnom strukturom čije su glavne značajke bifurkacije, varijacije u promjeru žila definirane Murrayevim zakonom te specifična topologija grananja prilagođena anatomskom obliku srca. Dodatni izazov u računalnoj analizi angiograma predstavlja činjenica da se zakrivljenost i prostorna orijentacija krvnih žila konstantno mijenjaju uslijed srčanih kontrakcija, što značajno komplicira proces automatske obrade slika [4].

Uz tradicionalnu angiografiju, suvremena medicina koristi i naprednije modalitete poput CT koronarne angiografije (CTCA) te MR angiografije (MRA). Navedene tehnologije omogućuju trodimenzionalni prikaz krvožilnog sustava na neinvazivan način, iako sa sobom nose nedostatke poput veće doze zračenja ili potrebe za znatno skupljom opremom. U tom kontekstu, primjena sintetskih podataka pokazuje izniman potencijal i korisnost za unaprjeđenje sva tri spomenuta modaliteta [5].

2.2. Proceduralno generiranje vaskularnih mreža

Kada je u pitanju proceduralno generiranje krvnih žila, danas se oslanja na nekoliko različitih pristupa. Najstarija metoda temelji se na Lindenmayerovim sustavima (tzv. L-sustavima), koji modeliraju grananje žila koristeći rekurzivna pravila za prepisivanje stringova. S druge strane, noviji pristupi uključuju naprednije koncepte:

- Constrained Constructive Optimization (CCO): Algoritam koji izgrađuje arterijsko stablo s ciljem minimizacije metaboličkog troška transporta krvi, pritom strogo pazeći na sva hemodinamska ograničenja unutar sustava.

- Algoritam kolonizacije prostora (Space colonization algorithm): Kod ove metode, svaki pojedini segment krvne žile "kolonizira" okolni prostor tako da privlači vršne točke prema unaprijed definiranim točkama rasta. Ovo rješenje omogućuje iznimnu fleksibilnost pri oblikovanju konačne vaskularne mreže.
- Fraktalni modeli i L-sustavi: Iako prisutni dulje vrijeme, i dalje su vrlo praktični za brzu sintezu struktura kod kojih je potrebno imati jasnu kontrolu nad složenošću mreže.
- Simulacije temeljene na dinamici fluida (CFD): Rješavanjem Navier-Stokesovih jednadžbi unutar generirane mreže dobiva se vrlo realističan prikaz raspodjele brzine protoka i tlaka, što u konačnici direktno utječe na autentičan vizualni izgled angiograma.

Danas se u modernoj praksi najčešće koristi kombinacija ovih metoda. Na primjer, CCO se koristi za definiranje glavne, makroskopske topologije koronarnog stabla, dok se CFD simulacije i stohastički modeli brinu za mikrovaskularni sloj kako bi se dodao maksimalan realizam na razini samih kapilara [6].

2.3. Sinteza angiogramskih slika

Kada se uspješno generira vaskularna mreža, iduća ključna faza je renderiranje samog sintetskog angiograma kako bi on vizualno što vjernije oponašao stvarni klinički snimak. Da bi se postigao visoka razina realizma, potrebno je obratiti pozornost na nekoliko ključnih faktora:

- Modeliranje kontrasta i intenziteta: Intenzitet pojedinog piksela na snimci postavlja se proporcionalno lokalnoj koncentraciji kontrastnog sredstva, što izravno ovisi o samom promjeru krvne žile, ali i o brzini protoka krvi kroz nju.

- Prostorna projekcija i perspektiva: Trodimenzionalna računalna mreža žila projicira se na dvodimenzionalnu ravninu pod različitim kutovima snimanja kako bi se simulirao rad rendgenskog uređaja.

- Šum i artefakti: Kako bi se simulirale nesavršenosti stvarnih uređaja, pomoću analitičkih ili empirijskih modela dodaju se popratni šumovi poput *shot* šuma, *speckle* šuma te strukturnog šuma pozadine. Standardni pristup u ovom koraku uključuje implementaciju aditivnog Gaussova i Poissonova šuma.

- Srčani pokreti: Kontrakcije i gibanje srca modeliraju se kroz periodička deformacijska polja, što rezultira prirodnim vizualnim zamućenjem (*motion blur*) na snimkama.

- Preklapanje anatomskih struktura: Kako bi angiogram izgledao autentično, u obzir se uzima i preklapanje okolnih struktura poput kostiju rebara, dijafragme te same sjene srčane konture.

Krajnji rezultat cijelog ovog procesa je sintetska slika koja vizualno u potpunosti odgovara pravim kliničkim snimkama. Njezina najveća prednost leži u tome što dolazi s automatski generiranim i preciznim oznakama segmentacije, uključujući točne maske žila, lokacije bifurkacija te promjere pojedinih segmenata. [7]

2.4. State of the art – relevantni radovi i alati

Među prvim značajnim doprinosima u ovom području ističe se open-source alat VascuSynth, koji su razvili Hamarneh i Jassi (2010.). Ovaj alat omogućuje računalno generiranje trodimenzionalnih vaskularnih stabala primjenom CCO pristupa. Premda je primarno bio namijenjen modeliranju jetrene i cerebralne vaskulature, VascuSynth je uspješno prilagođen i za sintezu koronarnih struktura unutar trodimenzionalne CT angiografske domene [8].

Nadalje, razvila se proširena inačica CCO modela koja je u potpunosti prilagođena specifičnoj sferičnoj geometriji lijeve srčane klijetke, što je predstavljalo ključni napredak usmjeren upravo na koronarnu domenu. Ovo rješenje uspješno reproducira realističan raspored koronarnih žila, uz fiziološki utemeljenu ovisnost promjera krvne žile o samom kutu grananja [9].

Značajan iskorak donose i istraživanja u kojima se CFD simulacije integriraju sa sintetskim koronarnim geometrijama dobivenim proceduralnim putem. Dokazano je da računalni modeli trenirani na takvim sintetskim podacima mogu s visokom pouzdanošću predvidjeti kritična mjesta s povišenim rizikom od razvoja ateroskleroze, i to na temelju analize distribucije tangencijalnog naprezanja stijenke (engl. *wall shear stress* – WSS) [10].

U novije vrijeme, generativne suparničke mreže (GAN) pronašle su široku primjenu u prilagodbi domene (engl. *domain adaptation*) sintetskih koronarnih angiograma. Arhitekture poput CycleGAN-a koriste se za transformaciju proceduralno renderiranih slika kako bi one vizualno odgovarale domeni stvarnih kliničkih snimaka, čime se drastično smanjuje razlika u distribuciji podataka (engl. *domain gap*). [11]

Najsuvremeniji trend u ovom području predstavlja implementacija difuzijskih modela, kod kojih vaskularna topologija služi kao uvjetni kontrolni signal. Pokazuje se da DDPM modeli, uvjetovani proceduralnom skicom koronarne mreže, generiraju iznimno realistične sintetske angiograme. Ti modeli daju bolje performanse nego GAN pristup, što otvara vrata stvaranju još raznolikijih i autentičnijih skupova podataka za treniranje računalnih modela [12].

Konačno, važno je istaknuti i javno dostupan skup podataka ASOCA (*Automated Segmentation of Coronary Arteries*, 2020.), koji je potaknuo intenzivan razvoj metoda za automatsku segmentaciju koronarnih arterija iz CT angiograma. Međutim, ASOCA sadrži svega 40 ručno anotiranih CTCA snimaka, a upravo je taj nedostatak i usko grlo u količini podataka glavni motiv zbog kojeg se razvija sintetska generacija slika [13].

3. OPIS ZADATKA S DOBIVENIM REZULTATIMA

3.1. Cilj zadatka

Cilj zadatka bio je implementirati algoritam za generiranje sintetskih angiograma koji se mogu koristit za treniranje i evaluaciju modela za segmentaciju krvnih žila.

3.2. Metodologija

Cjelokupni računalni cjevovod implementiran je proceduralno unutar programskog jezika Python, uz oslonac na standardne biblioteke NumPy, OpenCV i SciPy. Sustav je strukturiran kroz četiri odvojena sloja čiji se doprinosi na kraju linearno zbrajaju u konačnu sliku. Ovakav pristup izravno simulira stvarni fizikalni proces u kojem se prigušenja rendgenskih zraka kroz različita tkiva i anatomske strukture preklapaju na jedinstvenom detektoru.

Prvi sloj predstavlja tzv. *watercolor* pozadinu koja se generira naprednom tehnikom izobličenja domene (engl. *domain warping*). Prije samog generiranja šuma, koordinatni se prostor deformira pomoću dva neovisna polja pomaka dobivena iz glatkog fraktalnog šuma. Preko tako izmijenjenih koordinata uzorkuje se višeoktavni šum s pet oktava opadajuće amplitude. Rezultat ovog postupka su meke, organski razmazane mrlje koje se prirodno prelijevaju jedna u drugu, čime se uspješno izbjegava pojava pravilnih kružnih oblika karakterističnih za klasični Perlinov šum bez tehnike izobličenja. Na samom kraju, ovom se sloju dodaju blagi radijalni pad svjetline prema rubovima i aditivni Gaussov šum zrnatosti.

Drugi sloj sadrži proceduralno generirano vaskularno stablo koje se izgrađuje rekurzivnim algoritmom. Generiranje započinje iz početne točke (smještenog na vrhu kateterskog uvoda) te se grana kroz anatomske bifurkacije. Na svakom se čvorištu vaskularni tok dijeli na dvije ili tri kćeri grane. Sukladno Murrayevom zakonu raspodjele radijusa, svaka nova grana u hijerarhiji postaje kraća i tanja od svog roditelja prema formuli:

$$r^3 = \sum r_i^3$$

Svaki pojedini segment žile iscrtava se kao niz točkastih otisaka (krugova) duž blago zakrivljene putanje. Promjer se postupno sužava, a smjer kretanja podliježe nasumičnoj, ali strogo kontroliranoj promjeni kuta (do ±0.16 radijana po koraku), što sprječava nastanak nerealnih,

strogo geometrijskih oblika. Početni kut grananja također je stohastički definiran (±35° u odnosu na vertikalu), što osigurava da svaki generirani uzorak posjeduje jedinstvenu globalnu orijentaciju stabla. Vjerojatnost daljnjeg grananja raste s dubinom strukture i regulirana je parametrom *branching_density*, s time da je grananje na prve dvije razine dubine fiksno zadano kako algoritam ne bi prerano prekinuo sintezu i stablo sveo na samo jednu nerazgranatu nit.

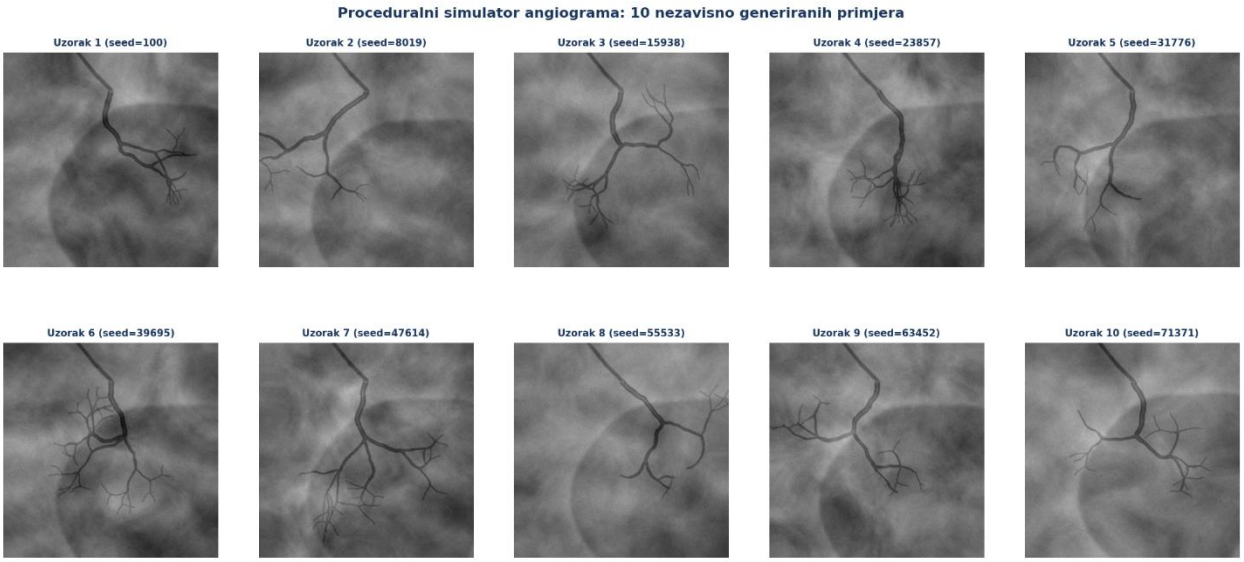
Vizualni profil same krvne žile temelji se na lokalnom sjenčanju cjevovoda koje uzima u obzir trenutni polumjer (engl. *radius-aware tube-shading*). Za svaku se točku pamti pripadajući polumjer tijekom iscrtavanja, pa se Euklidska udaljenost do najbližeg nevaskularnog piksela normalizira upravo na taj lokalni polumjer, a ne na globalni maksimum cijele maske. Na taj način svaka žila, bez obzira na svoju debljinu, dobiva fizikalno ispravan profil s tamnijim rubovima i svjetlijom sredinom, čime se vjerno imitira manja apsorpcija kontrastnog sredstva u središnjem dijelu lumena na stvarnom rendgenskom snimku.

Treći i četvrti sloj obuhvaćaju siluetu srca. Silueta srca modelirana je implicitnom elipsoidnom jednadžbom uz primjenu funkcije *rng.uniform* za nasumični odabir pomaka i polumjera unutar fiziološki opravdanih granica. Kako bi se izbjegao efekt umjetne prozirne folije s oštrim rubovima, rubovi elipsoida dodatno se distorziraju pomoću sinusno-kosinusnih funkcija te se zamućuju mekim Gaussovim filtrom.

U završnoj fazi, svi se slojevi linearno zbrajaju, nakon čega se dodaje kvantni šum koji simulira ponašanje stvarnog rendgenskog detektora. Dodatno se primjenjuje blagi usmjereni filtar zamućenja (*motion-blur*) za simulaciju mikropomaka srca tijekom same ekspozicije, kao i radijalno vinjetiranje za pad intenziteta svjetla prema rubovima detektora. Svaki generirani angiogram posjeduje vlastitu cjelobrojnu klicu (*seed*) koja se prosljeđuje kroz sve strukturne slojeve. To jamči da je svaki proizvedeni uzorak u potpunosti neovisan i jedinstven, a ne samo estetska varijacija jedne te iste anatomske podloge.

3.3. Dobiveni rezultati

Implementirani generator testiran je generiranjem deset primjera angiograma, svaki sa svojim zasebnim, međusobno razmaknutim seed-om. Slika 1 prikazuje mrežu svih deset generiranih primjera.



Slika 1: Deset nezavisno generiranih sintetičkih angiograma

Vizualnom inspekcijom svih deset primjera potvrđeno je da je cilj zadatka ostvaren. Svaki primjer ima vlastitu, međusobno različitu topologiju vaskularnog stabla, vlastitu veličinu i položaj siluete srca, dok pozadinska watercolor tekstura nikada nije identična između dva primjera. Niti jedan od deset primjera ne sadrži prazno ili nepotpuno generirano stablo, što potvrđuje da mehanizam grananja na prve dvije razine dubine pouzdano sprječava prijevremen prekid rasta stabla.

Slika 2 prikazuje sedmi uzorak generiranog angiograma u većoj rezoluciji, koji se detaljno vizualno interpretira u nastavku.

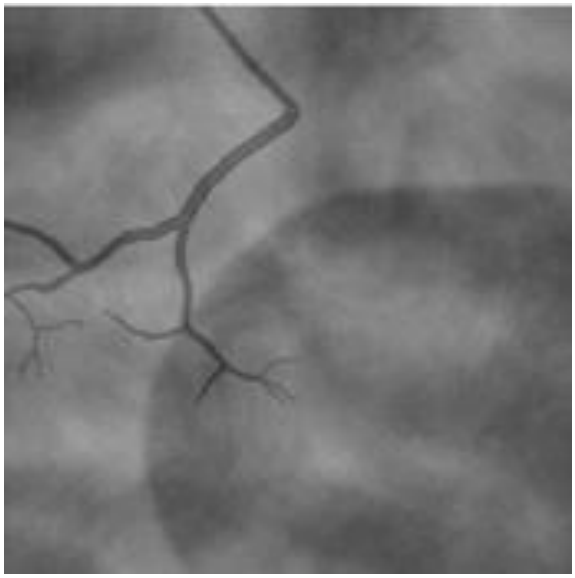


Slika 2: Uzorak 7 generiranog angiograma

Generirana slika pokazuju sličnost sa stvarnim angiografskim snimkama jer algoritam uspješno oponaša nekoliko ključnih elemenata medicinskih prikaza. Kateter koji služi za ubrizgavanje kontrastnog sredstva u krvne žile, medicinski ispravno je oblikovan. Algoritam je također uspješno prikazao prirodno stanjivanje žila, pa je glavna žila najdeblja na početku, a sa svakim novim grananjem postaje tanja. Cijela mreža žila smještena je unutar siluete srca, iako same žile ne prate u potpunosti stvarnu zakrivljenost površine srca. Izgled medicinske snimke dodatno je simuliran kroz efekte svjetla i sjene, poput svijetlog obruča oko siluete organa koji odgovara ponašanju rendgenskih zraka pri prolasku kroz gušća tkiva. Sama pozadina sadrži sitni šum i različite nijanse sive boje, što je zadovoljavajuće jer imitira izgled prave rendgenske snimke.

Detaljnim pregledom slika uočavaju se određene pogreške koje jasno pokazuju da je prikaz generiran računalno. Primjerice, na samom spoju katetera i žile nalazi se previše oštar prekid zbog kojeg izgleda kao da je kateter odvojen od krvnih žila, što se u stvarnosti ne može dogoditi. Zatim, na krajevima krvnih žila uočava se neprirodno grananje jer žile gube zaobljenost i postaju ravne. Generiranim žilama nedostaje privid dubine i trodimenzionalnosti. Na stvarnim angiogramima, kada žila mijenja smjer i ulazi u prostor koji se na dvodimenzionalnoj slici ne može izravno prikazati, vidi se prividno zadebljanje na mjestu gdje se ona račva ili savija. Ovaj efekt dubine nedostaje na svim generiranim angiogramima. Još jedan veliki nedostatak je ispuna organa, odnosno srca. Silueta srca trebala bi imati ujednačenu gustoću i svjetlinu na svim svojim dijelovima. Umjesto toga, na generiranim slikama uočavaju se nepravilne svjetlije i tamnije mrlje, što stvara vizualne nekonzistentnosti koje ne odgovaraju stvarnim angiogramima.

Slika 3 prikazuje drugačiji primjer angiograma, koji je analiziran u nastavku.



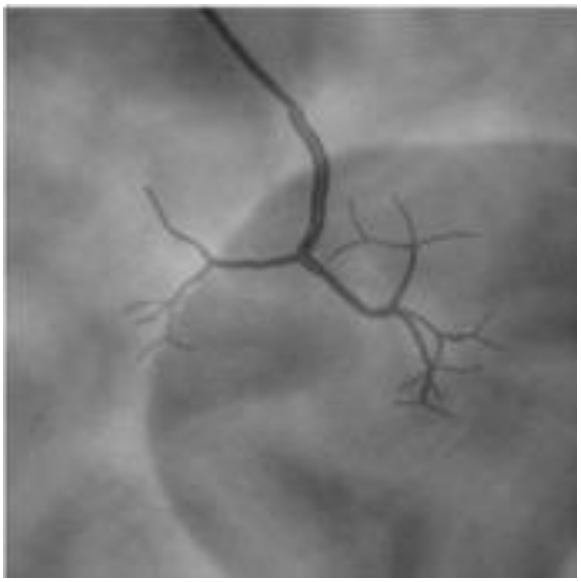
Slika 3: Uzorak 2 generiranog angiograma

Slika pokazuje manji stupanj uvjerljivosti u odnosu na prethodne rezultate. Uočava se da vaskularna mreža nije izrazito razgranata te da se žila dijeli nekoliko puta prije nego što grananje stane. Iako bi se to na prvi pogled moglo smatrati nedostatkom, na stvarnim angiogramima često je uočljivo manji broj grana, pa ovakav prikaz i dalje ostaje medicinski ispravan. Značajnije odstupanje predstavlja položaj same žile u odnosu na sjenu organa. Dok se na slici jasno vidi tamnija kružna površina koja predstavlja srce, generirana žila se pozicionira prema lijevoj strani i u potpunosti zaobilazi srce. U stvarnoj anatomiji, koronarne arterije moraju pratiti vanjsku površinu samog organa kako bi ga opskrbljivale krvlju, pa ovaj smještaj žile predstavlja medicinsku nepravilnost. Za razliku od ostalih generiranih prikaza, na ovoj se slici ne može primijetiti prijelaz iz katetera u krvnu žilu, što znači da su te dvije strukture izravno spojene. Međutim, i u ovom se segmentu pojavljuje nepravilnost. Budući da je kateter u stvarnosti fleksibilna, savitljiva plastična cijev, on bi morao prirodno pratiti geometriju žile koja odmah skreće ulijevo. Umjesto glatkog i zaobljenog savijanja cijelog spoja ulijevo, na slici je vidljivo neprirodno i naglo skretanje pod kutom, što ne odgovara ponašanju spoja u stvarnim uvjetima.

Unatoč navedenim problemima, slika uspješno zadržava osnovne vizualne karakteristike medicinskog snimka. Pozadina i sitni digitalni šum, odnosno zrnatost ekrana, pridonose dojmu stvarne medicinske snimke. Prisutnost tamnije strukture u desnom dijelu uspješno simulira sjenu organa unutar prsnog koša. Kao i na prethodno analiziranom angiogramu, silueta srca trebala bi imati ujednačenu gustoću i svjetlinu na svim svojim dijelovima, što vidimo da ovdje nije slučaj. Algoritam je ispravno implementirao stanjivanja žila, pa promjer žila postaje sve uži prema

njihovom završetku. Prvo odvajanje žila izvedeno je pod prirodnim kutom, što pokazuje da algoritam posjeduje dobru osnovu za generiranje račvanja.

Za kraj analizirati ćemo još osmi uzorak generiranog angiograma, koji je prikazan slikom 4.



Slika 4: Uzorak 8 generiranog angiograma

Treći analizirani uzorak zadržava osnovnu iluziju angiograma. Kao i kod prvog analiziranog primjera, mreža žila smještena je unutar siluete srca, iako same žile ne prate u potpunosti stvarnu zakrivljenost površine srca. Algoritam je uspješno implementirao debljinu žila, pa one progresivno postaju tanje kako se odmiču od izvora, čime se dobro oponaša slabljenje koncentracije kontrastnog sredstva na krajevima žila. Sjena srca ispravno je prikazana, ali kao i na prethodnim uzorcima, i ovdje se unutar te siluete srca uočava nejednolika raspodjela gustoće i svjetline.

S druge strane, na krajnjim dijelovima mreže, neke žile su zadržale tamnu boju i oštrinu umjesto da postupno blijede prema krajevima. Uz to, pojedini završetci se prekidaju naglo, što je jasni znak da je slika računalno generirana. Osim toga, na samom vrhu slike, na mjestu prijelaza katetera u početni segment krvne žile, ponovno je prisutan oštar prijelaz. Također, jedan od glavnih razloga zbog kojeg možemo vidjeti kako ova slika nije stvarni angiogram je račvanje glavne žile. Kod prvog račvanja žile, žile se račvaju pod potpuno neprirodnim kutom. Pozadina angiograma i na ovom primjeru ostaje zadovoljavajuća. Pozadina i sitni digitalni šum, odnosno zrnatost ekrana, precizno su pogođeni, a sivi prijelazi pridonose izgledu rendgenske snimke.

3.4. Analiza i interpretacija rezultata

Pošto ovaj rad ne pokriva treniranje modela za segmentaciju niti numeričku provjeru na pravim kliničkim podatcima, cijela analiza postignutih rezultata temelji se na detaljnom vizualnom pregledu generiranih angiograma (slika 1). Dobivene slike uspoređene su s anatomskim i fizičkim karakteristikama pravih rendgenskih snimaka, koje su ranije objašnjene u teorijskom dijelu. Kroz analizu je napravljen kritički osvrt na dobre stvari koje daju realističnost, ali i na greške koje jasno otkrivaju da su slike računalno generirane.

Mreža žila na slikama kreće od katetera koji je smješten na samom vrhu te se kroz nekoliko uzastopnih račvanja dijeli na sve tanje i kraće žile. Taj logični slijed, gdje deblji i dulji dijelovi postupno prelaze u mnoštvo sitnih ogranaka, vizualno zadovoljavajuće opisuje anatomiju pravih srčanih arterija. Kutovi pod kojima se žile odvajaju na najuspješnijim primjerima izgledaju prirodno, a same žile su blago zakrivljene i valovite. Zbog toga se izbjegla savršeno ravni izgled žila koja se inače odmah prepozna kod računalno generiranih primjera. Pozadina oko žila ne predstavlja uniformnu sivu plohu, nego ima meke, prirodno razmazane mrlje koje se glatko prelijevaju iz svjetlijih u tamnije tonove. Rubovi ovih gradijenata su zamućeni i nepravilni bez oštrih prijelaza, što potvrđuje uspješnu primjenu tehnike izobličenja domene. Dodatno, oko tamnijih sjena uočen je svijetli obruč, odnosno *halo* efekt, koji modelira prirodno raspršenje rendgenskih zraka pri prolasku kroz gušće anatomske strukture. Na cjelokupnu sliku primijenjen je šum koji uklanja uniformnost i pridonosi izgledu stvarnog angiograma.

Usporedna analiza svih deset generiranih primjera potvrđuje strukturalnu i topološku raznolikost. Vaskularna mreža na svakom pojedinom uzorku pruža se u različitim smjerovima, dok su broj račvanja i njihov raspored potpuno jedinstveni, a slične varijacije uočavaju se i u pozicioniranju te dimenzijama sjene srca. Navedene karakteristike dokazuju da implementacija nasumične vrijednosti (*seed*) kroz sve slojeve modela osigurava visoku razinu neovisnosti među generiranim uzorcima. Sustav stoga pokazuje izražen potencijal za generiranje velikih baza sintetskih podataka, budući da ne stvara samo površne estetske varijacije, već modelira potpuno nove anatomske konfiguracije. Međutim, za punu medicinsku autentičnost potrebno je dodati algoritam koji bi omogućio da krvne žile prate promjene u poziciji siluete srca.

Unatoč dobrim stranama generiranih angiograma, na gotovo svim uzorcima prisutni su pogreške koje narušavaju medicinsku ispravnost. Na mjestu spoja krutog katetera i početnog segmenta vaskularne mreže pojavljuje se oštar, ravan presjek koji narušava prirodni izgled prema kojoj kateter mora biti fizički umetnut unutar žile. Nadalje, dok su početna račvanja, na pojedinim primjerima, medicinski ispravna, na samim krajevima mreže uočavaju se značajna geometrijska odstupanja. Žile na pojedinim mjestima postaju izrazito ravne i krute. Dodatni problem predstavlja i sama silueta srca na kojoj se, umjesto homogene gustoće tkiva, kroz sve uzorke ponavlja nejednolika raspodjela svjetline i kontrasta. Na kraju, s obzirom na to da su strukture izvedene kao dvodimenzionalne projekcije, generiranim prikazima nedostaje napredniji efekt dubine, posebice na mjestima preklapanja te na samim spojevima vaskularnih ogranaka.

Ove greške ne umanjuju trenutnu vrijednost ovog generatora kao alata za skiciranje i ilustraciju osnovnih anatomskih struktura. No, ako bi se ovaj model htio koristiti za ozbiljno treniranje sustava računalnog vida za segmentaciju, ove probleme trebalo bi popraviti u nekom budućem radu.

4. ZAKLJUČAK

Zaključak rada jest da opisani pristup nudi iznimno brzu i računalno jeftinu alternativu za izgradnju baza slika koje mogu poslužiti kao izvrsna podloga za treniranje sustava umjetne inteligencije namijenjenih automatskoj segmentaciji u kardiologiji. Iako proceduralni model u trenutačnom obliku pokazuje visoku razinu vizualne uvjerljivosti, uočena topološka i fizikalna ograničenja ukazuju na jasne smjernice za budući razvoj. Daljnji skok u realističnosti i potpuna eliminacija preostalih računalnih nedostataka mogu se ostvariti implementacijom naprednijih generativnih algoritama, integracijom dubokih neuronskih mreža te korištenjem veće računalne snage koja bi omogućila simulaciju složene trodimenzionalne dinamike fluida. Time bi se generirani podatci podigli na razinu kliničke nerazlučivosti, što bi značajno unaprijedilo robusnost modela računalnog vida u stvarnim medicinskim primjenama.

LITERATURA

[1] World Health Organization, “Cardiovascular diseases (CVDs)”, World Health Organization.
Dostupno na: https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)

[2] Contributors to Wikimedia projects, “Angiography”, Wikipedia.
Dostupno na: https://en.wikipedia.org/wiki/Angiography

[3] Contributors to Wikimedia projects, “Coronary circulation”, Wikipedia.
Dostupno na: https://en.wikipedia.org/wiki/Coronary_circulation

[4] Contributors to Wikimedia projects, “Murray's law”, Wikipedia.
Dostupno na: https://en.wikipedia.org/wiki/Murray%27s_law

[5] Mayo Clinic Staff, “Coronary angiogram”, Mayo Clinic.
Dostupno na: https://www.mayoclinic.org/tests-procedures/coronary-angiogram/about/pac-20384653

[6] PubMed Central, “Parallel generation of extensive vascular networks with application to an archetypal human kidney model“, National Library of Medicine
Dostupno na: https://pmc.ncbi.nlm.nih.gov/articles/PMC8633801/

[7] M. Tkadlecová, T. Zikmund, P. Oberta, J. Kaiser, “Flat-Field based Characterization, Modeling and Simulation of Noise in a Digital X-ray Imaging System”, Department of Optical and Biophysical Systems, Institute of Physics of the Czech Academy of Sciences, Prague, Czech Republic.
Dostupno na: https://www.ndt.net/article/dir2025/papers/DIR2025-ShortPaper-M_TKADLECOVA-TU1B4.pdf

[8] G. Hamarneh, P. Jassi, "VascuSynth: Vascular Tree Synthesis Software", Medical Image Analysis Lab, Simon Fraser University, Canada.

Dostupno na: https://www.researchgate.net/publication/224271596_VascuSynth_Vascular_Tree_Synthesis_Software

[9] P. Juliani, R. Monterio, A. Correia, "Left ventricular chamber geometry in cardiomyopathies: insights from a computerized anatomical study", PubMed Central

Dostupno na: https://pmc.ncbi.nlm.nih.gov/articles/PMC5933952/

[10] U. Morbiducci, "Outflow conditions for image-based hemodynamic models of the carotid bifurcation: implications for indicators of abnormal flow", Frontiers in Bioengineering and Biotechnology

Dostupno na: https://scholar.google.com/citations?view_op=view_citation&hl=it&user=1QbyZ1gAAAAJ&citation_for_view=1QbyZ1gAAAAJ:mVmsd5A6BfQC

[11] O. Tmenova, R. Martin, L. Dong, "CycleGAN for style transfer in X-ray angiography", PubMed Central

Dostupno na: https://pubmed.ncbi.nlm.nih.gov/31286396/

[12] N. Moradi, G. Luijten, B. Hinrichs, J. Kleesiek, V. Alves, "VS-DDPM: Efficient Low-Cost Diffusion Model for Medical Modality Translation", Center Algoritmi / LASI, University of Minho, Braga, Portugal

Dostupno na: https://www.researchgate.net/publication/404247965_VS-DDPM_Efficient_Low-Cost_Diffusion_Model_for_Medical_Modality_Translation/link/69f0487e0f902c06323bc6ca/download?_tp=eyJjb250ZXh0Ijp7ImZpcnN0UGFnZSI6Il9kaXJlY3QiLCJwYWdlIjoicHVibGljYXRpb24ifX0

[13] ASOCA Challenge, "Automated Segmentation of Coronary Arteries," Grand Challenge.

Dostupno na: https://asoca.grand-challenge.org/